

DATOS MASIVOS II

ANÁLISIS DE COMPONENTES PRINCIPALES

Blanca Vázquez-Gómez y Gibran Fuentes-Pineda

29 de agosto de 2022

- Objetos cada vez más dispersos conforme aumenta el número de dimensiones

LA HIPÓTESIS DE LA VARIEDAD

- Ejemplos pueden vivir en una variedad de muchas menores dimensiones que el espacio original






Imagen tomada de Li and Jain, 2005

- Proyección ortogonal de un conjunto de vectores
- Genera una nueva vista
- Aplicaciones
 - Visualización
 - Extracción de características
 - Reducción de dimensionalidad
 - Compresión


INTUICIÓN: DATOS EN 2D




INTUICIÓN: DATOS VISTOS DESDE EL EJE x




INTUICIÓN: DATOS VISTOS DESDE EL EJE y




INTUICIÓN: NUEVOS EJES u_1 Y u_2



INTUICIÓN: DATOS PROYECTADOS SOBRE EL EJE u_1



INTUICIÓN: DATOS PROYECTADOS SOBRE EL EJE u_2



- Dado un conjunto de vectores $\mathbf{X} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(n)}\}$ de d dimensiones, el primer componente principal es el vector \mathbf{u}_1 que maximice la varianza de los datos proyectados, donde \mathbf{u}_1 es un vector de d dimensiones

- La proyección de un vector sobre el componente principal está dado por

$$\hat{\mathbf{x}}^{(i)} = \mathbf{u}_1^\top \mathbf{x}^{(i)}$$

PCA POR MÁXIMA VARIANZA (1)

- La proyección de un vector sobre el componente principal está dado por

$$\hat{\mathbf{x}}^{(i)} = \mathbf{u}_1^\top \mathbf{x}^{(i)}$$

- La media de los datos proyectados es $\mathbf{u}_1^\top \bar{\mathbf{x}}$, donde

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}^{(i)}$$

PCA POR MÁXIMA VARIANZA (1)

- La proyección de un vector sobre el componente principal está dado por

$$\hat{\mathbf{x}}^{(i)} = \mathbf{u}_1^\top \mathbf{x}^{(i)}$$

- La media de los datos proyectados es $\mathbf{u}_1^\top \bar{\mathbf{x}}$, donde

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}^{(i)}$$

- La varianza es $\frac{1}{n} \sum_{i=1}^n [\mathbf{u}_1^\top \mathbf{x}^{(i)} - \mathbf{u}_1^\top \bar{\mathbf{x}}]^2 = \mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$, donde

$$\mathbf{S} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}^{(i)} - \bar{\mathbf{x}})(\mathbf{x}^{(i)} - \bar{\mathbf{x}})^\top$$

PCA POR MÁXIMA VARIANZA (2)

- Queremos encontrar el vector \mathbf{u}_1 que maximice la varianza de los datos proyectados $\mathbf{u}_1^\top \mathbf{S} \mathbf{u}_1$, con la restricción que $\mathbf{u}_1^\top \mathbf{u}_1 = 1$

PCA POR MÁXIMA VARIANZA (2)

- Queremos encontrar el vector \mathbf{u}_1 que maximice la varianza de los datos proyectados $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$, con la restricción que $\mathbf{u}_1^T \mathbf{u}_1 = 1$
- Podemos formular esta restricción usando multiplicadores de Lagrange: $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 + \lambda_1(1 - \mathbf{u}_1^T \mathbf{u}_1)$

PCA POR MÁXIMA VARIANZA (2)

- Queremos encontrar el vector \mathbf{u}_1 que maximice la varianza de los datos proyectados $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$, con la restricción que $\mathbf{u}_1^T \mathbf{u}_1 = 1$
- Podemos formular esta restricción usando multiplicadores de Lagrange: $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 + \lambda_1(1 - \mathbf{u}_1^T \mathbf{u}_1)$
- Derivando e igualando a cero, tenemos

$$\mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1$$

PCA POR MÁXIMA VARIANZA (2)

- Queremos encontrar el vector \mathbf{u}_1 que maximice la varianza de los datos proyectados $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$, con la restricción que $\mathbf{u}_1^T \mathbf{u}_1 = 1$
- Podemos formular esta restricción usando multiplicadores de Lagrange: $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 + \lambda_1(1 - \mathbf{u}_1^T \mathbf{u}_1)$

- Derivando e igualando a cero, tenemos

$$\mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1$$

- Esto es, \mathbf{u}_1 es un vector propio de \mathbf{S} , donde $\lambda_1 = \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$ es su valor propio que se corresponde con la varianza de los datos proyectados

- El siguiente componente principal es el vector propio que maximice la varianza de los datos proyectados entre el conjunto de vectores ortogonales a los que ya han sido elegidos.

Este proceso se realiza de forma incremental hasta obtener los K componentes principales.

- El conjunto de K componentes principales forman una base ortonormal de funciones.

- Para proyectar un vector $\mathbf{x}^{(i)}$ sobre los componentes principales

$$\mathbf{z}^{(i)} = \mathbf{U}^\top [\mathbf{x}^{(i)} - \bar{\mathbf{x}}]$$

donde $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_K]$ es una matriz cuyas columnas se corresponden con los K componentes principales.

- La reconstrucción está dada por

$$\hat{\mathbf{x}}^{(i)} = \mathbf{U}\mathbf{z}^{(i)} + \bar{\mathbf{x}}$$

PCA POR VECTORES Y VALORES PROPIOS

- Busca subespacio de K dimensiones que maximiza varianza (o minimiza error) de los ejemplos
 - Definido por eigenvectores $\mathbf{u}_1, \dots, \mathbf{u}_K$ con eigenvalores más grandes $\lambda_1, \dots, \lambda_K$ de la matriz de covarianza





Figura tomada de Wikipedia (Principal Component Analysis)

PCA APLICADO A IMÁGENES DE ROSTROS

- Componentes principales se toman como base (**eigenfaces**)
- Nuevos rostros se proyectan en subespacio encontrado para ser comparados



SOLUCIÓN POR SVD (1)

- Para cualquier matriz \mathbf{X} de $n \times d$, la descomposición SVD está dada por

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

- Substituyendo en $\mathbf{X}^T\mathbf{X}$ tenemos

$$\begin{aligned}\mathbf{X}^T\mathbf{X} &= \left(\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\right)^T \left(\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\right) = \mathbf{V}\mathbf{\Sigma}^T \underbrace{\mathbf{U}^T\mathbf{U}}_{\mathbf{I}}\mathbf{\Sigma}\mathbf{V}^T \\ &= \mathbf{V} \underbrace{\mathbf{\Sigma}^T\mathbf{\Sigma}}_{\mathbf{D}}\mathbf{V}^T = \mathbf{V}\mathbf{D}\mathbf{V}^T\end{aligned}$$

- Si $\mathbf{C} = \mathbf{X}^T\mathbf{X}$ y multiplicamos ambos lados por \mathbf{V}

$$\mathbf{C}\mathbf{V} = \mathbf{V}\mathbf{D} \underbrace{\mathbf{V}^T\mathbf{V}}_{\mathbf{I}} = \mathbf{V}\mathbf{D}$$

- Entonces, los vectores propios de \mathbf{C}^1 se corresponden con \mathbf{V} y sus valores propios asociados con la diagonal de \mathbf{D} . Cuando \mathbf{X} está centrado, esto corresponde a PCA sin

SOLUCIÓN POR SVD (2)

- De forma equivalente

$$\begin{aligned}\mathbf{X}\mathbf{X}^T &= (\mathbf{U}\Sigma\mathbf{V}^T) (\mathbf{U}\Sigma\mathbf{V}^T)^T = \mathbf{U}\Sigma \underbrace{\mathbf{V}^T\mathbf{V}}_{\mathbf{I}} \Sigma^T \mathbf{U}^T \\ &= \mathbf{U} \underbrace{\Sigma\Sigma^T}_{\mathbf{D}} \mathbf{U}^T = \mathbf{U}\mathbf{D}\mathbf{U}^T\end{aligned}$$

- Si $\mathbf{C} = \mathbf{X}\mathbf{X}^T$ y multiplicamos ambos lados por \mathbf{U}



$$\mathbf{C}\mathbf{U} = \mathbf{U}\mathbf{D} \underbrace{\mathbf{U}^T\mathbf{U}}_{\mathbf{I}} = \mathbf{U}\mathbf{D}$$

- Entonces, los vectores propios de \mathbf{C}^2 se corresponden con

\mathbf{U} y sus valores propios asociados con la diagonal de \mathbf{D}

²Si \mathbf{X} está centrada se correspondería con la matriz de covarianza sin la división entre $n - 1$

PCA INCREMENTAL



Ejemplo de <http://scikit-learn.org>